



UNIVERSIDAD AUTÓNOMA DE ZACATECAS

"FRANCISCO GARCÍA SALINAS"

UNIDAD ACADÉMICA DE CIENCIA Y TECNOLOGÍA DE LA LUZ Y LA MATERIA

DETECCIÓN DE MALEZA EN CULTIVOS DE AGAVE DE TEMPRANA EDAD, MEDIANTE REDES NEURONALES CONVOLUCIONALES PROFUNDAS

PROTOCOLO

PRESENTA:

Raúl Edaurdo Venegas Reyes

DIRECTORES DE TESIS:

Dr. Tonatiuh Saucedo Anaya

Dr. Carlos Alejandro Guerrero Méndez

Zacatecas, Zac. Diciembre del 2025

Índice

1 Introducción **2**
1.1 Antecedentes 2
1.2 Estado del arte 4

2 Planteamiento del problema **5**

3 Justificación **6**

4 Hipótesis **6**

5 Objetivos **6**
5.1 Objetivo general 6
5.2 Objetivos particulares 6

6 Metas **7**

7 Metodología **8**

8 Cronograma de actividades **9**

9 Contribución **10**

10 Productos esperados **10**

11 Alcances y delimitaciones **10**

12 Equipo de trabajo disponible y por obtener **11**

13 Bibliografía **12**

1 Introducción

El desarrollo de sistemas de agricultura autónomos o de precisión se ha vuelto significativo en años recientes como una opción para incrementar la eficiencia, reducir costos y disminuir el trabajo manual en el campo. En este escenario, se hace imprescindible disponer de algoritmos fiables que sean capaces de analizar el entorno y apoyar en la tomar decisiones en tiempo real. Esta investigación se enfoca en la creación de un algoritmo basado en redes neuronales profundas, diseñado para ser incorporado a un sistema autónomo de deshierbe agrícola. Su finalidad es detectar maleza en el cultivo de agave y establecer las bases para su eliminación automática.

Las presencia de malezas en los cultivos de agave suponen un problema agronómico importante, sobre todo en las primeras etapas fonológicas del cultivo, cuando las plantas tienen mayor vulnerabilidad a la competencia por agua, nutrientes y luz. La falta de control oportuno de la maleza puede afectar el desarrollo del agave, aumentar los costos operativos y reducir el rendimiento final. La necesidad de controlar la maleza de manera anticipada y selectiva ha impulsado el uso de herramientas de agricultura de precisión, que tienen como objetivo aplicar insumos y trabajos justo donde se requieren, en el momento y cantidad apropiados.

Los sistemas ópticos han asumido un rol primordial en la agricultura de precisión. A través de sensores ópticos como cámaras especializadas, es posible diferenciar cultivo y maleza, estimar su distribución espacial y generar mapas o señales de control para equipos inteligentes en campo. El uso de redes neuronales profundas en combinación con estos sistemas ópticos permite mejorar la capacidad de detección, incluso bajo condiciones cambiantes de iluminación y fondo, lo brinda la oportunidad de creara nuevas soluciones más autónomas y robustas para el manejo de malezas.

En el presente protocolo se propone el desarrollo y la evaluación de un algoritmo de redes neuronales utilizando imágenes en tiempo real para la detección de maleza en cultivos de agave de edad temprana, implementado en una tarjeta embebida de bajo costo. El algoritmo estará orientado a generar los parámetros necesarios para el accionamiento de un sistema deshiervador agrícola, sin abordar en este trabajo el diseño mecánico del mismo. De esta manera, se busca aportar una base metodológica que permita avanzar hacia la limpieza automatizada de cultivos de agave, contribuyendo en una gestión más eficiente, precisa y económicamente accesible del control de malezas.

1.1 Antecedentes

La agricultura de precisión surge como una solución a la necesidad de hacer un uso más eficiente y sostenible de los recursos en el campo. Esta se fundamenta en el uso de tecnologías como sistemas de posicionamiento global (GPS/GNSS), sensores electrónicos, imágenes satelitales o aéreas y plataformas digitales para apoyar la toma de decisiones, con la finalidad de aplicar insumos "en la dosis correcta, en el lugar correcto y en el momento oportuno" [1] [2]. En este enfoque, se busca reconocer la variabilidad espacial y temporal de los cultivos para ajustar labores como el riego, la fertilización, la protección de cultivos y el manejo de malezas, aprovechando datos de sensores de suelo, clima e historial de rendimiento. [1]

Dentro de la agricultura de precisión, los sistemas de visión artificial y los sensores ópticos, han cobrado un especial protagonismo en la gestión de malezas. Diversos trabajos destacan el uso de cámaras RGB y técnicas de procesamiento

de imagen para distinguir suelo, cultivo y flora arvense a nivel de parcela [3]. Estudio mas reciente muestra la incorporación de aprendizaje profundo (deep learning) en el reconocimiento cultivo–maleza, así como el uso de cámaras Lidar (Light Detection and Ranging), RGB ó multiespectrales para mejorar notablemente la precisión de las detecciones y permitir avanzar hacia la automatización de decisiones en equipos inteligentes [4].

A su vez, se han desarrollado sistemas para detección de malezas en tiempo real acoplados a herramientas agrícolas. En la literatura se reportan equipos de aspersión dirigida (spot spraying) donde modelos ligeros de YOLO, ligeros y optimizados para correr en plataformas embebidas, activan válvulas de aplicación de herbicidas sólo en las áreas donde se detecta la maleza, lo que permite reducir significativamente el volumen del producto aplicado y manteniendo niveles de control adecuados [5]. Estas soluciones, implementadas en plataformas de prueba y robots agrícolas, demuestran que la combinación de la visión computacional con actuadores pueden resultar en un ahorro importante de insumos y por ende la reducción al impacto ambiental por manejo químico de malezas [5] [6] .

En México, la adopción de prácticas de agricultura de precisión ha sido gradual, con mayor presencia en cultivos extensivos y frutales, donde se emplean sensores de suelo (humedad, temperatura, etc.), drones , mapas de rendimiento o prescripción y sistemas de aplicación variable para la optimización de riego y fertilización [7]. Sin embargo, el manejo de malezas sigue apoyándose mayoritariamente en el control químico. Revisiones recientes sobre la resistencia a herbicidas en México documentan un número creciente de casos de malezas con una alta resistencia a diferentes modos de acción, lo que refuerza la necesidad de utilizar alternativas no químicas y de un uso más racional de los herbicidas en los sistemas productivos nacionales [8] [9].

En el caso específico del agave, las malezas constituyen uno de los problemas fitosanitarios más frecuentes. Se reporta la presencia de pastos, arbustos y malezas trepadoras, tanto de hoja ancha como angosta; las gramíneas suelen ser las más abundantes, mientras que las malezas de hoja ancha, aunque menos numerosas, muestran mayor diversidad de especies. Estas especies compiten con el agave por agua, nutrimentos y luz, pueden sombrear las plantas y actuar como hospederas de plagas y enfermedades, ocasionando reducciones importantes en el crecimiento y el rendimiento [7].

En términos de agricultura precisión aplicada al agave, se han desarrollado trabajos que emplean imágenes RGB y multiespectrales capturadas mediante vehículos aéreos no tripulados (UAV) y redes convolucionales para la detección y cuantificación de plantas de agave, con el objetivo de estimar la densidad de plantas y apoyar el monitoreo del cultivo. Por ejemplo, Espinoza-Hernández et al. (2023) evaluaron algoritmos tipo YOLOv4 y YOLOv4-tiny sobre imágenes de alta resolución para determinar la densidad de agave, alcanzando valores altos de exactitud y F1, lo que demuestra el potencial del deep learning para el conteo y localización de plantas en este cultivo [10].

En el estado de Zacatecas, que se caracteriza por un clima en su mayoría semiárido y recursos hídricos limitados, los documentos técnicos subrayan la importancia de conservar los cultivos libres de malezas para evitar la competencia por el escaso recurso hídrico y por los nutrientes [11]. Esta situación se puede extrapolar al agave en etapas tempranas, en donde el sistema radicular aún es poco desarrollado y la planta es sensible a la competencia.

Finalmente, el avance de la inteligencia artificial en tiempo real, y en particular de las redes neuronales profundas capaces de procesar video a bordo de plataformas móviles, abre la posibilidad de implementar rastrillos o deshier-

vadores autónomos guiados por sistemas ópticos, capaces de determinen de manera automática dónde se encuentra la maleza y cuándo es necesario actuar [5] [4]. El proyecto que se presenta entra precisamente en esta tendencia; el cual se centra en el desarrollo de un algoritmo basado en redes neuronales profundas para la detección de maleza en plantíos de agave de edad temprana en tiempo real, proporcionando los datos necesarios para que un sistema deshiervador mecánico no invasivo actúe con mayor precisión y con el menor impacto posible sobre el cultivo.

1.2 Estado del arte

2003 Whelan y McBratney introducen el concepto de manejabilidad sitio–específica dentro de la agricultura de precisión, subrayando la importancia de reconocer la variabilidad intra–parcelaria para tomar decisiones diferenciadas [12].

2005 McBratney et al. definen formalmente la agricultura de precisión como un sistema de manejo que busca aplicar insumos en la "cantidad correcta, en el lugar correcto y en el momento oportuno", apoyado en sensores y mapas de variabilidad [13].

2010–2014 Diversos trabajos aplican visión por computadora clásica (segmentación por color, índices de vegetación y textura) para separar cultivo y maleza, mostrando buenas prestaciones en condiciones controladas pero alta sensibilidad a cambios de iluminación y fondo [14].

2019 Wang et al. publican una revisión sobre detección de malezas con visión terrestre, describiendo el uso de cámaras RGB y técnicas de procesamiento de imagen para distinguir suelo, cultivo y flora arvense, y anticipando la migración hacia métodos de deep learning [3].

2019 Se introducen las primeras aplicaciones de redes neuronales convolucionales en agricultura para clasificación y segmentación cultivo–maleza, demostrando que las CNN superan a los métodos tradicionales en precisión y robustez en campo [15].

2022 Wang et al. presentan el conjunto de datos Weed25, con 25 especies de malezas etiquetadas, y evalúan detectores como YOLOv3, YOLOv5 y Faster R–CNN, marcando un referente para el entrenamiento y comparación de modelos de detección de malezas [16].

2023 Fan et al. y otros autores desarrollan sistemas de aspersión dirigida (spot spraying) basados en modelos ligeros tipo YOLO, montados en maquinaria agrícola, que permiten aplicar herbicida únicamente donde se detecta la maleza, reduciendo significativamente el volumen aplicado [17].

2023 Flores et al. utilizan imágenes RGB obtenidas con UAV y redes convolucionales para la detección y conteo automático de plantas de agave, automatizando el monitoreo de densidad de plantas en plantaciones comerciales [18].

2023 Espinoza–Hernández et al. emplean YOLOv4 y YOLOv4–tiny para estimar la densidad de plantas de agave en imágenes aéreas, mostrando que variantes ligeras pueden mantener alta exactitud con menor costo computacional [10].

2024 Qu y Su publican una revisión sobre reconocimiento cultivo–maleza con deep learning en equipos agrícolas inteligentes, concluyendo que modelos YOLO en sus versiones ligeras permiten detección en tiempo real adecuada para implementación en plataformas embebidas [4].

2024–2025 Se proponen modelos especializados para detección de malezas (HDMS–YOLO, PD–YOLO, Star–YOLO), diseñados para mejorar la detección

de objetos pequeños y reducir parámetros y GFLOPs, facilitando su uso en hardware de bajo consumo [19] [20] [21] [22].

2025 Trabajos recientes integran modelos YOLO en sistemas embebidos y robots agrícolas, demostrando la viabilidad de realizar detección de malezas en tiempo real a bordo de plataformas móviles y de generar señales de control para deshierbe mecánico o aspersión dirigida, lo que abre la posibilidad de sistemas autónomos aplicados a cultivos perennes como el agave [5] [23].

2 Planteamiento del problema

En México, el cultivo de agave, especialmente Agave tequilana, tiene un gran impacto en términos económicos y sociales. No obstante, en sus etapas tempranas de crecimiento, enfrenta un problema crucial: la presencia de maleza que compiten por agua, luz y nutrientes, comprometiendo el rendimiento a futuro. En regiones con clima semiárido, como Zacatecas, esta situación es particularmente importante ya que el recurso hídrico es muy limitado y la competencia por la humedad en el suelo tierra se traduce en pérdidas de vigor como de productividad.

Actualmente, el control de maleza en agave se realiza mayoritariamente mediante aplicación de herbicidas y deshierbe manual o semimecanizado. Por un lado uno incrementa los costos y genera daño ambiental, en el caso de deshierbe a manual se requiere mucha mano de obra, es lento y puede provocar daños a las plantas jóvenes si no se realiza con cuidado. A pesar de que la agricultura de precisión da herramientas para el manejo eficiente de los insumos, en el caso del agave aún no se a logrado la adopción de sistemas inteligentes de detección y deshierbe dirigido.

A nivel internacional existen equipos agrícola de deshierbe inteligente con sistema de visión e inteligencia artificial integrados; sin embargo la mayoría son importados, costosos y no están al alcance de la mayoría de los productores locales de Zacatecas. Esto genera una brecha entre el avance tecnológico disponible y las posibilidades reales de implementación en campo.

El desarrollo reciente de la inteligencia artificial en tiempo real, especialmente las redes neuronales profundas capaces de procesar video a bordo de plataformas móviles, se ha demostrado que es una alternativa viable para detectar malezas en otros cultivos y guiar sistemas de aspersión dirigida o deshierbe mecánico. Sin embargo, para el caso del cultivo de agave aún no se cuenta con un sistema validado que, utilizando una cámara RGB montada en un tractor o implemento deshiervador, permita detectar en tiempo real la maleza presente en plantíos de agave y genere información espacial suficiente para accionar de manera segura y precisa un mecanismo de deshierbe mecánico.

3 Justificación

La maleza es un problema crucial en el cultivo de agave, especialmente en las etapas tempranas, cuando la planta es pequeña y susceptible. En zonas semiáridas como Zacatecas, la competencia por agua y nutrientes entre agave y maleza reduce el crecimiento, genera plantaciones desuniformes y reduce el rendimiento.

Actualmente, el control de la maleza se basa en su mayoría en herbicidas y en el deshierbe manual. Los herbicidas son costosos y tienen impactos ambientales; al deshierbe manual es lento, requiere mucha mano de obra y resulta poco viable cuando se manejan superficies grandes. A pesar de que existen equipos de deshierbe inteligentes llegan a ser muy costosa e inaccesible para muchos agricultores mexicanos.

Por lo tanto, se justifica desarrollar un modelo de redes neuronales profundas que, utilizando una cámara RGB montada en un implemento deshiervador, detecte la maleza en tiempo real y proporcione la información necesaria para guiar un mecanismo que la elimine sin dañar el agave. La intención es contar contar con una solución funcional y de bajo costo, adaptada a las condiciones de los productores, que reduzca el uso de herbicidas y la dependencia de mano de obra intensiva, mejorando al mismo tiempo la productividad y la sostenibilidad del cultivo.

4 Hipótesis

Si se implementa un algoritmo de detección de maleza basado en redes neuronales profundas, utilizando imágenes RGB capturadas por una cámara montada en un sistema deshiervador agrícola e implementado en una plataforma embebida, entonces será posible identificar en tiempo real la maleza en plantíos de agave de edad temprana con la precisión suficiente para guiar un mecanismo de deshierbe mecánico no invasivo para su eliminación.

5 Objetivos

5.1 Objetivo general

Desarrollar y validar un algoritmo de detección de maleza basado en redes neuronales profundas, entrenado con imágenes RGB capturadas en campo y desplegado en una plataforma embebida (Raspberry Pi) montada en un sistema deshiervador agrícola, que permita identificar en tiempo real la maleza en plantíos de agave de edad temprana y guiar un mecanismo de deshierbe mecánico no invasivo para su eliminación.

5.2 Objetivos particulares

- Obtener imágenes y videos RGB de campos de plantíos de agave de edad temprana, con una cámara ubicada en la posición prevista para el sistema deshiervador.
- Construir y etiquetar un conjunto de datos de imágenes (agave / maleza) a partir de los videos capturados, con la finalidad de emplearlos en el entrenamiento y validación del modelo.
- Entrenar un modelo de detección de objetos basado en redes neuronales profundas (YOLOv8) para la identificación de maleza y agave, evaluando su desempeño mediante métricas como mAP, precisión y recall.

- Implementar el modelo entrenado en una plataforma embebida (Rasberry Pi), y evaluar su desempeño en tiempo real en términos de velocidad de inferencia y latencia extremo a extremo (captura- detección)
- Diseñar e integrar un esquema de comunicación entre la Raspberry Pi y los actuadores del mecanismo, de manera que las detecciones de maleza generen señales de activación sincronizadas con la posición del implemento.

6 Metas

- Generar una base de datos multiclase (agave / maleza), lista para entrenamiento y validación de modelo.
- Obtener un modelo de detección de maleza entrenado con YOLOv8 confiable y estable.
- Integrar un prototipo funcional donde la Rasberry Pi reciba la imagen de la cámara, ejecute el modelo de detección y envíe señales de activación a los actuadores.

7 Metodología

La metodología para esta investigación se ha estructurado en cuatro fases principales.

- **Adquisición y preparación de datos**: Se seleccionará una parcela de agave de edad temprana en la región de Zacatecas y se montará una cámara RGB en la posición aproximada que ocupará en el sistema deshiervador (altura y ángulo respecto al surco). Con esta cámara se grabarán videos recorriendo los surcos bajo distintas condiciones de iluminación y niveles de infestación de maleza. A partir de estos videos se extraerán imágenes (frames) representativas, que posteriormente serán importadas a una plataforma de etiquetado (Roboflow) para marcar manualmente las clases "agave" y "maleza". El resultado será un conjunto de datos de imágenes RGB etiquetadas, dividido en subconjuntos de entrenamiento, validación y prueba.

- **Diseño, entrenamiento y validación del modelo de detección**: Se utilizara una arquitectura ligera de redes neuronales profundas (YOLO), adecuada para su posterior implementación en una plataforma embebida. El modelo se entrenará con las imágenes etiquetadas previamente, ajustando hiperparámetros como tamaño de la imagen, número de épocas, etc. Se evaluara su desempeño mediante métricas como mAP (Mean Average Precision), precisión y recall sobre los conjuntos de validación y prueba, seleccionando la versión que logre el mejor equilibrio entre exactitud y complejidad computacional.

- **Implementación del modelo en una Rasberry Pi**: El modelo previamente entrenado se exportará a un formato compatible con la plataforma embebida y se montara en una Rasberry Pi conectada a la cámara RGB. Se desarrollara un programa que capture imágenes en tiempo real, ejecute la inferencia del modelo y obtenga las detecciones de maleza en cada frame. En esta parte se medirá la velocidad del procesamiento (FPS) y la latencia total de la imagen, para realizar las optimizaciones necesarias (ajuste de resolución) para asegurar un correcto funcionamiento muy cercano al tiempo real en condiciones de campo.

- **Salida de datos hacia los actuadores del sistema deshiervador**: Una vez teniendo las detecciones del modelo (coordenadas y clases), se desarrollara un módulo de cálculo que generara los parámetros necesarios para el sistema mecánico, como la posición relativa de la maleza dentro del área de trabajo y señales lógicas de activación de los actuadores. Estos parámetros se enviarán desde la Raspberry Pi mediante la interfaz de comunicación (GPIO, UART o serial).

8 Cronograma de actividades

Table 1: Cronograma de actividades

Actividad	2025				2026										
	S	O	N	D	E	F	M	A	M	J	J	A	S	O	N
Conceptualización															
Revisión bibliográfica y estado del arte	x	x	x	x	x	x	x	x	x	x	x	x	x		
Definición de requerimientos del sistema y protocolo		x	x	x	x										
Generación de base de datos															
Toma de videos en campo						x	x	x							
Extracción y etiquetado de imágenes (Roboflow)							x	x	x						
Diseño y entrenamiento del modelo															
Configuración del entorno y pruebas preliminares								x	x						
Entrenamiento y ajuste del modelo YOLOv8									x	x	x	x			
Implementación embebida y salida de parámetros															
Implementación del modelo en Raspberry Pi										x	x	x			
Pruebas de inferencia en tiempo real												x	x		
Diseño del módulo de salida de parámetros a actuadores											x	x	x		
Validación y resultados															
Validación del sistema de detección en campo													x	x	
Redacción de la tesis												x	x	x	x
Revisión y corrección de la tesis													x	x	x
Sustentación de tesis															x

9 Contribución

Realizar un modelo de IA basado en redes neuronales profundas (YOLOv8) e implementada en una tarjeta embebida (Raspberry Pi), con la finalidad de detectar en tiempo real la maleza en plantíos de agave de edad temprana y generar los parámetros necesarios para apoyar el accionamiento de un sistema deshiervador mecánico no invasivo.

10 Productos esperados

- **Base de datos de imágenes propia:** Colección categorizada de imágenes obtenidas en plantíos de agave, etiquetadas en clases como agave y maleza, preparadas para entrenamiento y validación de modelos de IA.
- **Modelo de detección entrenado (YOLOv8):** Red neuronal profunda ajustada para la identificación de maleza en plantíos de agave.
- **Implementación en tarjeta embebida:** Versión funcional del modelo de detección corriendo en una Raspberry Pi conectada a una cámara RGB, capaz de realizar inferencias en tiempo real.
- **Presentación en congreso:** Difusión de los resultados preliminares o finales del trabajo realizado en un congreso nacional o internacional relacionado con el tema.
- **Publicación científica:** Redacción y envío de un artículo a una revista científica o congreso especializado en visión computacional o ciencias agropecuarias.
- **Tesis de maestría:** Documento final que recopile el desarrollo metodológico, resultados y conclusiones del proyecto de investigación.

11 Alcances y delimitaciones

El presente proyecto se centra exclusivamente en el desarrollo y evaluación de un modelo de detección de maleza basado en redes neuronales profundas y su implementación en una plataforma embebida (Raspberry Pi). El alcance incluye la construcción de una base de datos de imágenes RGB de plantíos de agave de edad temprana, el entrenamiento del modelo de detección, su despliegue en la Raspberry Pi y la generación de parámetros de salida que puedan ser utilizados por un sistema deshiervador mecánico no invasivo.

El proyecto no incluye el diseño, fabricación ni validación mecánica completa del deshiervador. Asimismo, el estudio se delimita a plantíos de agave de edad temprana en condiciones de clima semiárido, utilizando cámaras RGB convencionales; no se consideran sensores multiespectrales ni otros cultivos distintos al agave.

12 Equipo de trabajo disponible y por obtener

- Material bibliográfico
- Equipo de laboratorio y herramienta básica.
- Cámara IP Hikvision DS-2CD1343G0-I(C), 4 Megapixel con lente de 2.8mm.
- Raspberry Pi 3 Modelo B+ con pantalla de visualización.
- Equipo de cómputo:
  - Tarjeta gráfica: NVIDIA GeForce RTX 5050 GDDR7 de 8Gb.
  - Procesador: Intel Core i5-13450HX de 13ª Generación. 10 nucleos y 16 hilos.
  - Memoria RAM: 24 GB DDR5-4800MT/s.
  - Almacenamiento: 512GB M.2
- Software:
  - Entorno de desarrollo en Python.
  - Librería YOLOv8 (Ultralytics) para el entrenamiento y despliegue del modelo de detección.
  - Plataforma de etiquetado de imágenes (Roboflow).

13 Bibliografía

[1] E. García, "Agricultura de precisión," no. 8, pp. 45–52, 2008.

[2] *Agricultura de Precisión — Intagri S.C.* es. Accessed: Dec. 4, 2025. [Online]. Available: https://www.intagri.com/articulos/poscosecha-comercializacion/agricultura-de-precision.

[3] A. Wang, W. Zhang, and X. Wei, "A review on weed detection using ground-based machine vision and image processing techniques," *Computers and Electronics in Agriculture*, vol. 158, pp. 226–240, Mar. 2019, ISSN: 0168-1699. DOI: 10.1016/j.compag.2019.02.005. Accessed: Dec. 4, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0168169918317150.

[4] H.-R. Qu and W.-H. Su, "Deep Learning-Based Weed–Crop Recognition for Smart Agricultural Equipment: A Review," en, *Agronomy*, vol. 14, no. 2, p. 363, Feb. 2024, Publisher: Multidisciplinary Digital Publishing Institute, ISSN: 2073-4395. DOI: 10.3390/agronomy14020363. Accessed: Dec. 4, 2025. [Online]. Available: https://www.mdpi.com/2073-4395/14/2/363.

[5] H. Wang et al., "Deep learning-based target spraying control of weeds in wheat fields at tillering stage," English, *Frontiers in Plant Science*, vol. 16, Mar. 2025, Publisher: Frontiers, ISSN: 1664-462X. DOI: 10.3389/fpls.2025.1540722. Accessed: Dec. 4, 2025. [Online]. Available: https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2025.1540722/full.

[6] V. Vijayakumar, Y. Ampatzidis, C. Lacerda, T. Burks, W. S. Lee, and J. Schueller, "AI-driven real-time weed detection and robotic smart spraying for optimised performance and operational speed in vegetable production," *Biosystems Engineering*, vol. 259, p. 104 288, Oct. 2025, ISSN: 1537-5110. DOI: 10.1016/j.biosystemseng.2025.104288. Accessed: Dec. 4, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1537511025002247.

[7] *Control de malezas en agave azul 1ª parte*, es, Feb. 2023. Accessed: Dec. 8, 2025. [Online]. Available: https://eldespertardelcampo.com.mx/2023/02/28/control-de-malezas-en-agave-azul-1a-parte/.

[8] J. A. Domínguez-Valenzuela et al., "Weed Resistance to Herbicides in Mexico: A Review," en, *Agronomy*, vol. 15, no. 10, p. 2411, Oct. 2025, Publisher: Multidisciplinary Digital Publishing Institute, ISSN: 2073-4395. DOI: 10.3390/agronomy15102411. Accessed: Dec. 5, 2025. [Online]. Available: https://www.mdpi.com/2073-4395/15/10/2411.

[9] J. L. Arispe- Vázquez, "Review of the current panorama of glyphosate resistance.," *Agroproductividad*, pp. 89–98, 2023.

[10] J. Espinoza-Hernández, "Agave plant density using convolutional neural networks and RGB aerial imagery," *Agrociencia*, 2023.

[11] *Agenda técnica agrícola de zacatecas*, es, 2015.

[12] B. M. Whelan, A. B. McBratney, and A. Stein, "On-farm field experiments for precision agriculture," English, in *Precision Agriculture*, Brill Nijhoff, Oct. 2003, pp. 731–737. DOI: 10.3920/9789086865147_112. Accessed: Dec. 8, 2025. [Online]. Available: https://research.wur.nl/en/publications/on-farm-field-experiments-for-precision-agriculture/.

[13] A. McBratney, B. Whelan, T. Ancev, and J. Bouma, "Future Directions of Precision Agriculture," en, *Precision Agriculture*, vol. 6, no. 1, pp. 7–23, Feb. 2005, ISSN: 1573-1618. DOI: 10.1007/s11119-005-0681-8. Accessed: Dec. 8, 2025. [Online]. Available: https://doi.org/10.1007/s11119-005-0681-8.

[14] Z. Wu, Y. Chen, B. Zhao, X. Kang, and Y. Ding, "Review of Weed Detection Methods Based on Computer Vision," eng, *Sensors (Basel, Switzerland)*, vol. 21, no. 11, p. 3647, May 2021, ISSN: 1424-8220. DOI: 10.3390/s21113647.

[15] A. Olsen et al., "DeepWeeds: A Multiclass Weed Species Image Dataset for Deep Learning," en, *Scientific Reports*, vol. 9, no. 1, p. 2058, Feb. 2019, Publisher: Nature Publishing Group, ISSN: 2045-2322. DOI: 10.1038/s41598-018-38343-3. Accessed: Dec. 8, 2025. [Online]. Available: https://www.nature.com/articles/s41598-018-38343-3.

[16] P. Wang et al., "Weed25: A deep learning dataset for weed identification," English, *Frontiers in Plant Science*, vol. 13, Nov. 2022, Publisher: Frontiers, ISSN: 1664-462X. DOI: 10.3389/fpls.2022.1053329. Accessed: Dec. 8, 2025. [Online]. Available: https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2022.1053329/full.

[17] X. Fan, X. Chai, J. Zhou, and T. Sun, "Deep learning based weed detection and target spraying robot system at seedling stage of cotton field," *Computers and Electronics in Agriculture*, vol. 214, p. 108 317, Nov. 2023, ISSN: 0168-1699. DOI: 10.1016/j.compag.2023.108317. Accessed: Dec. 8, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0168169923007056.

[18] D. Flores, I. González-Hernández, R. Lozano, J. M. Vazquez-Nicolas, and J. L. Hernandez Toral, "Automated Agave Detection and Counting Using a Convolutional Neural Network and Unmanned Aerial Systems," en, *Drones*, vol. 5, no. 1, p. 4, Mar. 2021, Publisher: Multidisciplinary Digital Publishing Institute, ISSN: 2504-446X. DOI: 10.3390/drones5010004. Accessed: Dec. 8, 2025. [Online]. Available: https://www.mdpi.com/2504-446X/5/1/4.

[19] L. Deng et al., "HAD-YOLO: An Accurate and Effective Weed Detection Model Based on Improved YOLOV5 Network," en, *Agronomy*, vol. 15, no. 1, p. 57, Jan. 2025, Publisher: Multidisciplinary Digital Publishing Institute, ISSN: 2073-4395. DOI: 10.3390/agronomy15010057. Accessed: Dec. 8, 2025. [Online]. Available: https://www.mdpi.com/2073-4395/15/1/57.

[20] J. Hua, R. He, Y. Zeng, and Q. Chen, "HDMS-YOLO: A multi-scale weed detection model for complex farmland environments," English, *Frontiers in Plant Science*, vol. 16, Oct. 2025, Publisher: Frontiers, ISSN: 1664-462X. DOI: 10.3389/fpls.2025.1696392. Accessed: Dec. 8, 2025. [Online]. Available: https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2025.1696392/full.

[21] S. Li, Z. Chen, J. Xie, H. Zhang, and J. Guo, "PD-YOLO: A novel weed detection method based on multi-scale feature fusion," English, *Frontiers in Plant Science*, vol. 16, Apr. 2025, Publisher: Frontiers, ISSN: 1664-462X. DOI: 10.3389/fpls.2025.1506524. Accessed: Dec. 8, 2025. [Online]. Available: https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2025.1506524/full.

[22] Z. Lu et al., "Star-YOLO: A lightweight and efficient model for weed detection in cotton fields using advanced YOLOv8 improvements," *Computers and Electronics in Agriculture*, vol. 235, p. 110 306, Aug. 2025, ISSN: 0168-1699. DOI: 10.1016/j.compag.2025.110306. Accessed: Dec. 8, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0168169925004120.

[23] A. H. Al-Ahmadi and A. K. Subr, "Smart sprayer for weed control using an object detection algorithm (yolov5)," *Journal of Plant Protection Research*, vol. 65, no. 3, pp. 312–323, 2025.