



UNIVERSIDAD AUTÓNOMA DE ZACATECAS

"FRANCISCO GARCÍA SALINAS"

UNIDAD ACADÉMICA DE CIENCIA Y TECNOLOGÍA DE LA LUZ Y LA MATERIA

DETECCIÓN DE MALEZA EN CULTIVOS DE AGAVE DE TEMPRANA EDAD, MEDIANTE REDES NEURONALES CONVOLUCIONALES PROFUNDAS

PROTOCOLO

PRESENTA:

Raúl Edaurdo Venegas Reyes

DIRECTORES DE TESIS:

Dr. Tonatiuh Saucedo Anaya

Dr. Carlos Alejandro Guerrero Méndez

Zacatecas, Zac. Diciembre del 2025

Índice

1 Introducción **2**
- 1.1 Estado del arte . . . 2
- 1.2 Planteamiento del problema . . . 4
- 1.3 Justificación . . . 4
- 1.4 Hipótesis . . . 4
- 1.5 Objetivo general . . . 5
- 1.6 Objetivos particulares . . . 5
- 1.7 Metodología . . . 5

2 Bibliografía **7**

1 Introducción

El presente proyecto de tesis se enfoca en el desarrollo de un sistema de visión artificial basado en redes neuronales profundas para apoyar tareas de agricultura de precisión en cultivos de agave de edad temprana. La agricultura de precisión busca optimizar el manejo de los cultivos mediante el uso de sensores, sistemas de adquisición de imágenes y plataformas computacionales que permitan obtener información del entorno y apoyar la toma de decisiones, con la finalidad de realizar las labores agrícolas de manera más eficiente y localizada [1] [2].

La problemática principal de este trabajo surge de la competencia que la maleza genera en las primeras etapas de desarrollo del agave. Durante esta etapa, la planta es más vulnerable a la competencia por agua, luz y nutrientes, lo cual puede afectar su crecimiento y reducir el rendimiento del cultivo. En el caso específico del agave, se ha reportado que las malezas compiten directamente con la planta y pueden afectar su desarrollo, por lo que su control oportuno resulta fundamental [3]. Esta situación es especialmente importante en regiones semiáridas como Zacatecas, donde el recurso hídrico es limitado y la competencia por humedad puede afectar el establecimiento del cultivo. Actualmente, el manejo de la maleza en cultivos de agave se realiza principalmente mediante deshierbe manual, semimecanizado o mediante la aplicación de herbicidas. Estas estrategias pueden implicar una elevada dependencia de mano de obra, mayores costos de operación y posibles efectos ambientales derivados del uso de productos químicos. Asimismo, durante el deshierbe manual o mecánico existe el riesgo de ocasionar daños al cultivo si las herramientas utilizadas entran en contacto con las plantas. Por esta razón, el uso de un sistema de visión artificial e inteligencia artificial representa una alternativa tecnológica para mejora tener un manejo más selectivo y preciso.

En los últimos años los sistemas de visión artificial están tomando un papel importante dentro de la agricultura de precisión. Con cámaras RGB y técnicas de procesamiento digital de imágenes se puede obtener información visual del cultivo y de su entorno. Por otra parte, la evolución de las redes neuronales profundas ha propiciado que los sistemas de visión posean una mayor habilidad para identificar objetos aun cuando las condiciones de iluminación, fondo, escala y orientación sean diversas. En particular, los modelos de detección de objetos basados en redes neuronales convolucionales son capaces de reconocer si una planta está presente en una imagen y su ubicación mediante cajas delimitadoras.

En el presente trabajo, se propone el desarrollo y la evaluación de un algoritmo de redes neuronales utilizando imágenes en tiempo real para la detección de agave en cultivos de edad temprana, implementados en una tarjeta embebida de bajo costo. El algoritmo estará orientado a generar los parámetros necesarios que permitan identificar la posición del agave y utilizar esta información para disminuir el riego de daño de la planta durante la eliminación de maleza. Esta propuesta busca contribuir al desarrollo de alternativas de agricultura de precisión de bajo costo que se adapten a las condiciones de producción del agave en la región.

1.1 Estado del arte

2003 Whelan et al. resaltan la importancia de reconocer las diferencias que se presentan al interior de una parcela, debido a que no todas sus áreas presentan las mismas características. Con estos datos se pueden realizar las labores agrícolas de una forma más precisa atendiendo las necesidades de cada zona. [4].

2005 McBratney et al. definen formalmente la agricultura de precisión como un sistema de manejo que busca aplicar insumos en la "cantidad correcta, en el lugar correcto y en el momento oportuno", apoyado en sensores y mapas de variabilidad **mcbratney˙future˙2005**.

2010–2014 Diversos trabajos comenzaron a utilizar técnicas de visión por computadora para separar cultivo, maleza y suelo mediante características como color, textura, forma e índices de vegetación. Aunque estos métodos mostraron resultados adecuados bajo condiciones controladas, su desempeño podía disminuir considerablemente ante variaciones de iluminación, sombras, cambios en el fondo y diferencias en el estado de desarrollo de las plantas. [5].

2019 Wang et al. publican una revisión sobre detección de malezas con visión terrestre, describiendo el uso de cámaras RGB y técnicas de procesamiento de imagen para distinguir suelo, cultivo y flora arvense, y anticipando la migración hacia métodos de deep learning [6].

2019 Olsen et al. publicaron el conjunto de datos DeepWeeds, formado por imágenes de diferentes especies de malezas adquiridas en condiciones reales. El trabajo demostró la capacidad de las redes neuronales convolucionales para distinguir diferentes tipos de vegetación [7].

2019 Flores et al. desarrollaron un sistema automático para la detección y conteo de plantas de agave mediante redes neuronales convolucionales e imágenes obtenidas desde vehículos aéreos no tripulados. El sistema alcanzó un valor de rendimiento F_1 de 0.96, demostrando la viabilidad del aprendizaje profundo para localizar plantas de agave dentro de plantaciones reales.

2022 Wang et al. presentan el conjunto de datos Weed25, con 25 especies de malezas etiquetadas, y evalúan detectores como YOLOv3, YOLOv5 y Faster R–CNN, marcando un referente para el entrenamiento y comparación de modelos de detección de malezas [8].

2023 Espinoza–Hernández et al. emplean YOLOv4 y YOLOv4–tiny para estimar la densidad de plantas de agave en imágenes aéreas, mostrando que variantes ligeras pueden mantener alta exactitud con menor costo computacional [9].

2024 Qu y Su publican una revisión sobre reconocimiento cultivo–maleza con deep learning en equipos agrícolas inteligentes, concluyendo que modelos YOLO en sus versiones ligeras permiten detección en tiempo real adecuada para implementación en plataformas embebidas [10].

2024 Xiang et al. realizaron una revisión específica sobre tecnologías de detección de cultivos y componentes mecánicos utilizados en sistemas inteligentes de deshierbe. Los autores distinguen dos estrategias principales: detectar directamente la maleza para accionar el mecanismo únicamente donde ésta se encuentra, o detectar el cultivo y realizar el deshierbe en las zonas donde no existen plantas cultivadas. Los autores señalan que esta segunda alternativa puede resultar especialmente conveniente debido a que las plantas del cultivo presentan una distribución más uniforme que la maleza y permiten establecer regiones de protección para evitar daños ocasionados por el mecanismo.

2024 Matadamas et al. evaluaron cinco modelos de aprenidizaje profundo (YOLOv7, YOLOv7-tiny, YOLOv8, Faster R-CNN y RetnaNet) para la detección y clasificación de plantas de Agave anfustifolia en plantaciones de Oaxaca, México. Utilizaron un dataset de 333 imágenes que contenían 1317 plantas etiquetadas. YOLOv7 obtuvo el mejor resultado global con un $mAP = 0.616$, mientras que YOLOv7-tiny y YOLOv8 alcanzaron un $mAP = 0.606$. El trabajo demostró la viabilidad de detectar agaves directamente desde imágenes tomadas a nivel de plantación y no únicamente mediante imágenes aéreas.

1.2 Planteamiento del problema

En México, el cultivo de agave, especialmente Agave tequilana, tiene un gran impacto en términos económicos y sociales. No obstante, en sus etapas tempranas de crecimiento, enfrenta un problema crucial: la presencia de maleza que compiten por agua, luz y nutrientes, comprometiendo el rendimiento a futuro. En regiones con clima semiárido, como Zacatecas, esta situación es particularmente importante ya que el recurso hídrico es muy limitado y la competencia por la humedad en el suelo tierra se traduce en pérdidas de vigor como de productividad.

Actualmente, el control de maleza se lleva a cabo principalmente a través del uso herbicidas, deshierbe manual o semimecanizado. Estas prácticas pueden incrementar los costos, requerir una considerable de mano de obra y, en el caso del deshierbe mecánico, provocar daños a las plantas jóvenes si la herramienta entra en contacto con ellas.

Si bien hay sistemas agrícolas que usan visión artificial e inteligencia artificial para tareas de deshierbe, su uso en los cultivos de agave todavía es limitado. De ahí la necesidad de desarrollar un sistema capaz de detectar y localizar las plantas de agave en tiempo real, de forma que su posición pueda ser utilizada como referencia para evitar que el mecanismo de deshierbe las dañe.

Así, el problema de investigación es si un modelo de redes neuronales profundas, con imágenes RGB adquiridas en campo, puede detectar y localizar plantas de agave de edad temprana con la precisión y velocidad necesarias para generar información útil para un sistema de deshierbe mecánico.

1.3 Justificación

La maleza es un problema crucial en el cultivo de agave, especialmente en las etapas tempranas, cuando la planta es pequeña y susceptible. En zonas semiáridas como Zacatecas, la competencia por agua y nutrientes entre agave y maleza reduce el crecimiento, genera plantaciones desuniformes y reduce el rendimiento.

Actualmente, el control de la maleza se basa en su mayoría en herbicidas y en el deshierbe manual. Los herbicidas son costosos y tienen impactos ambientales; al deshierbe manual es lento, requiere mucha mano de obra y resulta poco viable cuando se manejan superficies grandes. A pesar de que existen equipos de deshierbe inteligentes llegan a ser muy costosa e inaccesible para muchos agricultores mexicanos.

Por lo tanto, se justifica el desarrollo de un sistema de visión artificial basado en redes neuronales profundas que permita detectar y localizar las plantas de agave en tiempo real. La información obtenida mediante la detección podrá utilizarse para establecer zonas de protección alrededor del cultivo y generar parámetros que permitan a un mecanismo de deshierbe actuar sobre la vegetación circundante sin afectar las plantas de agave.

1.4 Hipótesis

Si se implementa un modelo de detección de agave basado en redes neuronales profundas y entrenado con imágenes RGB de plantas jóvenes adquiridas bajo condiciones reales de campo, entonces será posible detectar y localizar espacialmente el cultivo con precisión y velocidad suficientes para generar zonas de protección que permitan guiar un mecanismo de deshierbe mecánico y reducir el riesgo de daño a las plantas de agave.

1.5 Objetivo general

Desarrollar y validar un sistema de visión artificial basado en redes neuronales profundas para la detección y localización en tiempo real de plantas de agave de edad temprana mediante imágenes RGB y desplegado en una tarjeta embebida, con la finalidad de generar información espacial que permita guiar un mecanismo de deshierbe mecánico evitando dañar el cultivo.

1.6 Objetivos particulares

- Obtener imágenes y videos RGB de campos de plantíos de agave de edad temprana, con una cámara ubicada en la posición prevista para el sistema deshiervador.
- Construir y etiquetar un conjunto de datos de imágenes (agave) a partir de los videos capturados, con la finalidad de emplearlos en el entrenamiento y validación del modelo.
- Entrenar un modelo de detección de objetos basado en redes neuronales profundas (YOLOv16) para la identificación de maleza y agave, evaluando su desempeño mediante métricas como mAP, precisión y recall.
- Implementar el modelo entrenado en una plataforma embebida (Rasberry Pi), y evaluar su desempeño en tiempo real en términos de velocidad de inferencia y latencia extremo a extremo (captura- detección)
- Diseñar e integrar un esquema de comunicación entre la Raspberry Pi y los actuadores del mecanismo, de manera que las detecciones de maleza generen señales de activación sincronizadas con la posición del implemento.

1.7 Metodología

La metodología para esta investigación se ha estructurado en cuatro fases principales.

- **Adquisición y preparación de datos**: Se seleccionará una parcela de agave de edad temprana en la región de Zacatecas y se montará una cámara RGB en la posición aproximada que ocupará en el sistema deshiervador (altura y ángulo respecto al surco). Con esta cámara se grabarán videos recorriendo los surcos bajo distintas condiciones de iluminación y niveles de infestación de maleza. A partir de estos videos se extraerán imágenes (frames) representativas, que posteriormente serán importadas a una plataforma de etiquetado (Roboflow) para marcar manualmente la clase 'agave'. El resultado será un conjunto de datos de imágenes RGB etiquetadas, dividido en subconjuntos de entrenamiento, validación y prueba.
- **Diseño, entrenamiento y validación del modelo de detección**: Se utilizara una arquitectura ligera de redes neuronales profundas (YOLOv16), adecuada para su posterior implementación en una plataforma embebida. El modelo se entrenará con las imágenes etiquetadas previamente, ajustando hiperparámetros como tamaño de la imagen, número de épocas, etc. Se evaluara su desempeño mediante métricas como mAP (Mean Average Precision), precisión y recall sobre los conjuntos de validación y prueba, seleccionando la versión que logre el mejor equilibrio entre exactitud y complejidad computacional.

- **Implementación del modelo en una Rasberry Pi**: El modelo previamente entrenado se exportará a un formato compatible con la plataforma embebida y se montara en una Rasberry Pi conectada a la cámara RGB. Se desarrollara un programa que capture imágenes en tiempo real, ejecute la inferencia del modelo y obtenga las detecciones de agave en cada frame. En esta parte se medirá la velocidad del procesamiento (FPS) y la latencia total de la imagen, para realizar las optimizaciones necesarias (ajuste de resolución) para asegurar un correcto funcionamiento muy cercano al tiempo real en condiciones de campo.

- **Salida de datos hacia los actuadores del sistema deshiervador**: Una vez teniendo las detecciones del modelo (coordenadas y clases), se desarrollara un módulo de cálculo que generara los parámetros necesarios para el sistema mecánico, como la posición relativa de la maleza dentro del área de trabajo y señales lógicas de activación de los actuadores. Estos parámetros se enviarán desde la Raspberry Pi 4B mediante la interfaz de comunicación (GPIO, UART o serial).

2 Bibliografía

[1] E. García, "Agricultura de precisión," no. 8, pp. 45–52, 2008.

[2] *Agricultura de Precisión — Intagri S.C.* es. Accessed: Dec. 4, 2025. [Online]. Available: https://www.intagri.com/articulos/poscosecha-comercializacion/agricultura-de-precision

[3] *Control de malezas en agave azul 1ª parte*, es, Feb. 2023. Accessed: Dec. 8, 2025. [Online]. Available: https://eldespertardelcampo.com.mx/2023/02/28/control-de-malezas-en-agave-azul-1a-parte/

[4] B. M. Whelan, A. B. McBratney, and A. Stein, "On-farm field experiments for precision agriculture," English, in *Precision Agriculture*, Brill Nijhoff, Oct. 2003, pp. 731–737. DOI: 10.3920/9789086865147_112 Accessed: Dec. 8, 2025. [Online]. Available: https://research.wur.nl/en/publications/on-farm-field-experiments-for-precision-agriculture/

[5] Z. Wu, Y. Chen, B. Zhao, X. Kang, and Y. Ding, "Review of Weed Detection Methods Based on Computer Vision," eng, *Sensors (Basel, Switzerland)*, vol. 21, no. 11, p. 3647, May 2021, ISSN: 1424-8220. DOI: 10.3390/s21113647

[6] A. Wang, W. Zhang, and X. Wei, "A review on weed detection using ground-based machine vision and image processing techniques," *Computers and Electronics in Agriculture*, vol. 158, pp. 226–240, Mar. 2019, ISSN: 0168-1699. DOI: 10.1016/j.compag.2019.02.005 Accessed: Dec. 4, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0168169918317150

[7] A. Olsen et al., "DeepWeeds: A Multiclass Weed Species Image Dataset for Deep Learning," en, *Scientific Reports*, vol. 9, no. 1, p. 2058, Feb. 2019, Publisher: Nature Publishing Group, ISSN: 2045-2322. DOI: 10.1038/s41598-018-38343-3 Accessed: Dec. 8, 2025. [Online]. Available: https://www.nature.com/articles/s41598-018-38343-3

[8] P. Wang et al., "Weed25: A deep learning dataset for weed identification," English, *Frontiers in Plant Science*, vol. 13, Nov. 2022, Publisher: Frontiers, ISSN: 1664-462X. DOI: 10.3389/fpls.2022.1053329 Accessed: Dec. 8, 2025. [Online]. Available: https://www.frontiersin.org/journals/plant-science/articles/10.3389/fpls.2022.1053329/full

[9] J. Espinoza-Hernández, "Agave plant density using convolutional neural networks and RGB aerial imagery," *Agrociencia*, 2023.

[10] H.-R. Qu and W.-H. Su, "Deep Learning-Based Weed–Crop Recognition for Smart Agricultural Equipment: A Review," en, *Agronomy*, vol. 14, no. 2, p. 363, Feb. 2024, Publisher: Multidisciplinary Digital Publishing Institute, ISSN: 2073-4395. DOI: 10.3390/agronomy14020363 Accessed: Dec. 4, 2025. [Online]. Available: https://www.mdpi.com/2073-4395/14/2/363